

1조 1론머스크
공모전/논문/모두의 창업
증빙자료

문

- 논문 제목: iPhone 15 Pro 환경에서의 경량화 LLM 추론 최적화: Core ML 기반 양자화 및 프루닝 기법 비교 연구
- 이름: 김수빈
- 학회: 한국정보기술학회

© 2026 한국정보기술학회, 4차 산업혁명학회, 인공지능학회

iPhone 15 Pro 환경에서의 경량화 LLM 추론 최적화:
Core ML 기반 양자화 및 프루닝 기법 비교 연구

김수빈*, 박지민**

Optimization of Lightweight LLM Inference on
iPhone 15 Pro:
A Comparative Study of Core ML-based
Quantization and Pruning for On-Device AI

su-bin.kim*, ji-min.park**

*세명대학교 컴퓨터공학과, qsl1180@gmail.com

**세명대학교 컴퓨터공학과, hskwon@ksu.ac.kr(교신저자)

요약

Apple A17 Pro Neural Engine를 탑재한 iPhone 15 Pro 환경에서 대형 언어 모델(LLM)의 온디바이스 추론 최적화를 위한 Core ML 기반 양자화 및 구조적 프루닝 기법을 비교 분석한다. Llama-3.2-3B 모델을 대상으로 INT4 양자화(Core ML, Patterization), ATO, GPTQ, 80% 구조적 프루닝을 단독 및 복합 적용한 실험을 수행하였다. 실험 결과, Core ML, Patterization이 구조적 프루닝을 결합 시 모델 속도가 약 20% 감소하였으나, 추론 속도 또한 약 1.5배의 극한 성능 향상을 달성하였다. MLLM 환경에서도 유사한 결과를 나타내며, 온디바이스 환경에서 활용 가능한 수준을 유지하였다. 또한 Neural Engine 활용 시 GPU 기반 추론 대비 전력 소모도 80% 이상을 절감하였다.

Abstract

We compare and analyze Core ML-based quantization and structural pruning techniques for on-device LLM inference optimization on the iPhone 15 Pro equipped with Apple A17 Pro Neural Engine. Experiments were conducted on the Llama-3.2-3B model applying INT4 quantization (Core ML, Patterization, ATO) and 80% structural pruning individually and in combination. Results indicate that combining Core ML, Patterization with structural pruning can significantly reduce model size and improve inference speed while maintaining practical accuracy in on-device environments. Additionally, Neural Engine utilization also showed reduced power consumption compared to CPU-based execution.

Key words

On-device AI, iPhone 15 Pro, Core ML, LLM, Quantization, Pruning, Neural Engine, Edge Computing

1. 서론

모바일 AI 시대의 도래와 함께 인공지능의 대중화가 가속화되고 있다. Apple은 iPhone 15 Pro에 A17 Pro 칩을 탑재하고, 16개의 Neural Engine를 통해 최대 28 TOPS 수준의 AI 추론 성능을 지원하고 있다. 이는 기존에 비해 2배 이상 향상된 성능을 제공한다.

그러나 현재 주목받는 수십억 파라미터

규모의 LLM은 32GB RAM의 모바일 환경에서 실행하기 위해서는 모델 경량화가 필수적이다. Apple은 Core ML 프레임워크를 통해 INT4 양자화, 하드웨어 가속을 통한 구조적 프루닝 등 다양한 최적화 기법 간의 체계적 비교 연구를 위한 플랫폼을 제공한다.

본 논문은 iPhone 15 Pro 환경에서 Llama-3.2-3B 모델을 대상으로 Core ML, Patterization(NT4), ATO, 구조적 프루닝의 단독 및 복합 적용 성능을 실험하고, 추론

한국정보기술학회 (kinfores@gmail.com)

논문명 *

한글화 제목

2026년 한국정보기술학회 학제융합학술대회 및 대학논문발표대회에 참여해 주시길 진심으로 감사드립니다.

귀하께서 제출하신 논문이 6월 4일~5일 세종문화회관에서 개최되는 2026년 한국정보기술학회 학제융합학술대회 및 대학논문발표대회에 **대학논문발표대회부문(논문발표권)**에 자격이 있음을 알려드립니다.

- (1) 재택논문 : iPhone 15 Pro 환경에서의 경량화 LLM 추론 최적화: Core ML 기반 양자화 및 프루닝 기법 비교 연구
- (2) 저자 : 김수빈, 박지민
- (3) 발표 : 비대면 영상 발표
- (4) 발표시간 : 6월 4일(목) 오후, 6월 5일(금) 전일 (주무상세안내)

채택

논문

- 논문 제목: SDN 환경에서 AI 기반 컨테이너 태스크 오프로딩 시스템 및 테스트베드 구축
- 이름: 김민재
- 학회: 대한전자공학회

SDN 환경에서 AI 기반 컨테이너 태스크 오프로딩 시스템 및 테스트베드 구축

김민재, 김요한

계명대학교

E-mail : kimminjae0627@gmail.com, yhkim@kmu.ac.kr

Construction and Performance Analysis of an SDN-based Container Task Offloading Testbed

Minjae Kim, Yohan Kim
Keimyung University

Abstract

This paper presents an SDN-based container task offloading testbed using an SDN switch, ONOS controller, jason, edge node, and workstation compute node. The system compares jason local execution with workstation offloading using Docker-based containers and a AI-based offloading policy. Results show that data-intensive tasks are more efficient locally due to transfer overhead, while computation-intensive tasks benefit from workstation offloading.

1. 서론

넷지 컴퓨팅은 센서, 카메라, 임베디드 장치와 가계온도 센서에서 데이터를 처리함으로써 클라우드 중심 구조에서 발생하는 지연 시간과 네트워크 부하를 줄일 수 있는 구조로 주목받고 있다[1-3]. 특히 영상, 센서 스트림, IoT 데이터와 같이 실시간성이 요구되는 응용에서는 모든 데이터를 원격 클라우드로 전송된 뒤 처리하는 방식보다 데이터가 생성되는 지점 근처에서 일부 연산을 수행하는 방식이 유리하다. 그러나 jason과 같은 넷지 장치는 CPU, GPU, 메모리, 저장장치 성능이 제한되어서 대용량 유선 네트워크를 포함해서 처리하는 것은 비효율적일 수 있다. 따라서 모든 태스크를 워크스테이션이나 서버로 오프로딩하는 방식 역시 네티지 데이터가 큰 경우에는 대역폭, 전송, 원격 실행 관련 비용이 크게 발생할 수

있다. 따라서 넷지 환경에서는 태스크와 데이터 크기, 계산량, 네트워크 상태, 컨테이너 처리 효율성을 함께 고려하여 실행 위치를 선택해야 한다.

기존 오프로딩 넷지 컴퓨팅 및 태스크 오프로딩 연구에서는 태스크의 계산량, 데이터 크기, 네트워크 상태, 서버 부하 등을 고려하여 실행 위치를 결정하는 문제가 중요하게 다루어져 왔다[4]. 최근에는 코딩된 규칙이나 일정한 기반 방식에서 나아가, 강화학습 기반 에이전트가 현재 환경 상태를 관측하고 로딩 실행 또는 원격 오프로딩을 동적으로 선택하는 연구가 진행되고 있다[4-6]. 이러한 AI 기반 오프로딩 구조에서는 네티지 데이터 크기, 대역폭, 연산량, 네트워크 지연 시간, 대역폭, jason 및 워크스테이션의 CPU/메모리 사용률 등을 상태로 사용하고, 전체 완료 시간이나 전송 효율성을 보상으로 반영할 수 있다.

넷지 오프로딩 환경에서는 단순히 어느 노드에서 태스크를 실행할지 결정하는 것뿐만 아니라, 네트워크 상태를 관측하고 최적의 효율을 얻을 수 있는 구조가 필요하다. SDN은 제어 평면과 데이터 평면을 분리하여 네트워크 상태를 중앙에서 관측하고 용량 제어, 유동적 제어, 수평할 수 있으므로, 태스크 오프로딩 정책과 네트워크 제어를 결합하기에 적합하다. 따라서 본 연구에서는 SDN 기반 넷지 환경에서 컨테이너 태스크 오프로딩 실행을 수행할 수 있는 태스크오프로딩을 구축하고, AI 에이전트를 사용하여 지능적으로 jason 로딩 실행과 워크스테이션 간 오프로딩을 수행할 수 있는 구조를 제안하였다. 또한, 구현한 AI-SDN 제어 프레임워크에서 태스크와 데이터 크기에 따른 오프로딩 성능 평가를 수행하여 AI 기반 네트워크 자율운영의 가능성을 확인하였다.

[대한전자공학회] 2026년도 하계종합학술대회 접수논문 결과 통지

2026년도 하계종합학술대회 논문 제출 결과를 통보드립니다.


아래의 내용을 확인해 주세요.

논문제출 결과	Accept
논문번호	GEP-0909
논문제목	SDN 환경에서 AI 기반 컨테이너 태스크 오프로딩 시스템 및 테스트베드 구축
주저자명	김민재(계명대학교)
공동저자명	김민재(계명대학교)
교신저자명	김요한(계명대학교)

채택

논문

- 공모전 이름: 모두의 창업
- 참가자: 김민재, 김수빈, 김영서, 이현준, 박은서, 정양효



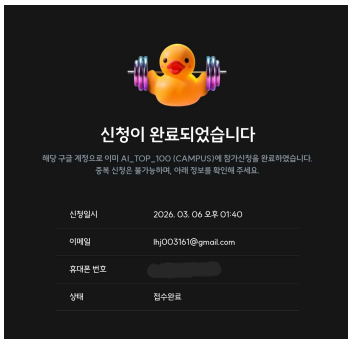
참가 인증 자료

- 공모전 이름: 국제지역학 포스터 논문 발표회
- 참가자: 이현준

[illegible]

참가 인증 자료

- 공모전 이름: AI_TOP_100
- 참가자: 이현준



참가 인증 자료

- 공모전 이름: KIT 바이브코딩 공모전
- 참가자: 김수빈

김수빈

2026년 4월 10일 (금) 오후 2:57, 임태종 <dla0625@koreaedugroup.com>님이 작성:

임태종 <dla0625@koreaedugroup.com>

 나에게 ▾

안녕하세요, KIT 바이브코딩 공모전 담당자입니다.

보내주신 공모작이 누락 없이 정상적으로 접수되었음을 확인해 드립니다.

고생 많으셨습니다. 좋은 결과 있으시길 바랍니다!

※ 혹시 GitHub 저장소에 API 키가 노출되어 있지는 않은지 다시 한번 확인 부탁드립니다. (보안 이슈 발생 시 금전적인 피해가 발생할 수 있습니다.)

참가 인증 자료

- 공모전 이름: 내가 만드는 교양과목 공모전
- 참가자: 김영서

참가(이수) 확인서

성명 : 김영서

학번 : 5819647

소속 : 컴퓨터공학부

상기 학생은 "2026학년도 내가 만드는 교양 과목 공모전" 프로그램
에 참가(이수) 하였음을 확인합니다.

※ 참여 프로그램 정보

가. 운영일자 : 2025.05.15~2025.05.15

나. 운영장소 : 온라인 접수

다. 참여시간 / 총 운영시간 : 2시간 / 2시간


라. 운영부서 : Tabula Rasa College - 인성교육원 행정팀

마. 담당자 : 정훈(☎053-580-6955)

계명대학교 기획처장



참가 인증 자료



수상

- 공모전 이름: 공공외교 프레젠테이션 대회
- 참가자: 김영서

Re: 공공외교_프레젠테이션_계명대학교_영도또

인쇄 번역

보낸사람 공공외교프레젠테이션 <pdcontest2022@gmail.com>

받는사람 김영서

2026년 5월 26일 (화) 오후 1:55

안녕하세요, 김영서 님

공공외교 프레젠테이션 대회에 관심을 가지고 신청해 주셔서 감사드립니다.
보내주신 참가신청서와 PPT 파일은 모두 정상적으로 접수되었습니다.
추후 진행 일정이나 추가 안내 사항이 있을 경우, 본 메일을 통해 다시 안내해 드리도록 하겠습니다.
좋은 결과가 있으시기를 응원합니다.
감사합니다.

공공외교 프레젠테이션 대회 진행 책임교수 최병덕 드림

2026년 5월 25일 (월) 오후 7:19, 김영서 <kygs0788@naver.com>님이 작성:
계명대학교 영도또팀 제출합니다

참가 인증 자료